

Deteksi Mutasi Titik Single-Nucleotide Polymorphism (SNP) pada Sekuens DNA, Prediksi Dampak terhadap Kodon Protein

IF3211 Domain-Specific Computation

Topik: DNA Sequence Analysis & Sequence Alignment

Surya Suharna, 18223075 Muhammad Faiz Alfikrona, 18223009 Ni Made Sekar Jelita P., 18223101

Program Studi Sistem dan Teknologi Informasi, Institut Teknologi Bandung

Abstrak

Single-Nucleotide Polymorphism (SNP) merupakan variasi genetik yang terjadi ketika satu basa nukleotida pada sekuens DNA mengalami perubahan pada posisi tertentu. SNP menjadi salah satu bentuk variasi genetik paling umum pada genom manusia dan dapat memengaruhi fungsi biologis apabila terjadi pada region penting dalam gen. Penelitian ini mengembangkan *pipeline* komputasi berbasis Python untuk mendeteksi SNP antara sekuens DNA referensi dan sampel, memprediksi dampaknya pada kodon protein, serta menilai patogenisitas klinis. *Pipeline* menggunakan algoritma Needleman-Wunsch (*global alignment*) dari Biopython, diikuti modul deteksi ORF pada enam *reading frame*, klasifikasi dampak mutasi (*silent*, *missense*, *nonsense*, *start_lost*, *stop_lost*, *frameshift*), *conservation scoring* berbasis Grantham distance, anotasi ClinVar, klasifikasi region genomik, dan penilaian patogenisitas (skor 0–1). Validasi pada dataset sintetik 1.500 bp dengan 150 SNP menghasilkan *precision*, *recall*, dan *F1-score* sempurna (1,000). Validasi pada fragmen gen β -globin (HBB) berhasil mereproduksi mutasi *sickle-cell* (GAG→GTG; Glu→Val) dengan *pathogenicity score* 0,787 dan *confidence high*. Eksperimen sensitivitas pada delapan tingkat densitas SNP (1,0–33,3%) menunjukkan $F1 \geq 0,97$ hingga densitas 20%.

Kata kunci: SNP, Needleman–Wunsch, Grantham distance, ClinVar, patogenisitas, β -globin, Biopython.


1. Pendahuluan

Genom organisme menyimpan informasi hereditas dalam sekuens nukleotida yang tersusun dari empat basa (A, T, G, C). Variasi sekuens di antara individu menjadi dasar genetika populasi, riset penyakit, dan farmakogenomika [1]. Bentuk variasi paling sederhana adalah *Single-Nucleotide Polymorphism (SNP)*, yaitu perbedaan satu basa pada lokus tertentu antara dua sekuens homolog. Pada region pengkode protein, SNP dapat berdampak *silent*, *missense*, atau *nonsense* [2].

Algoritma Needleman–Wunsch [3] digunakan untuk melakukan *global alignment*, yaitu menyelaraskan dua sekuens DNA secara menyeluruh agar posisi basa yang bersesuaian dapat dibandingkan dengan tepat. Melalui proses ini, perbedaan antarsekuens, seperti mutasi atau perubahan basa dapat lebih mudah diidentifikasi. Algoritma ini bekerja dengan pendekatan pemrograman dinamis untuk mencari alignment terbaik antara sekuens referensi dan sekuens sampel. Implementasinya dilakukan menggunakan Biopython [4] melalui kelas Bio.Align.PairwiseAligner yang menyediakan berbagai pengaturan *alignment* dan penalti *gap*.

Salah satu contoh penting dampak SNP ditunjukkan oleh penelitian Ingram [5]. Penelitian tersebut menyatakan bahwa

perubahan satu basa pada gen HBB (GAG→GTG) menyebabkan perubahan asam amino Glu→Val pada protein β -globin. Perubahan kecil tersebut berkaitan dengan *sickle-cell* anemia, yaitu kondisi ketika sel darah merah berubah bentuk menjadi menyerupai sabit dan mengganggu proses distribusi oksigen dalam tubuh.



Gambar 1. Perbandingan aliran darah pada normal red blood cell dengan sickle-cell anemia

(Sumber:

<https://sicklecelldiseasecanada.com/sickle-cell-anemia/>)

Akan tetapi, mendeteksi SNP saja tidak cukup, pertanyaan selanjutnya adalah apakah SNP tersebut berbahaya bagi organisme. Untuk menjawab hal ini, diperlukan beberapa analisis tambahan untuk menilai apakah suatu SNP berpotensi memengaruhi fungsi biologis atau berkaitan dengan penyakit tertentu. Pertama,

analisis *conservation*: posisi gen yang terkonservasi kuat di banyak spesies cenderung penting secara fungsional sehingga mutasi pada posisi tersebut lebih mungkin merusak. Kedua, anotasi ClinVar [6] yang mengumpulkan bukti-bukti klinis atau laporan tentang varian genetik dari laboratorium di seluruh dunia. Ketiga, konteks regional: SNP pada *exon coding* lebih berdampak daripada pada *intron*, kecuali jika berada di *splice site*. Keempat, Grantham [7] mengembangkan matriks jarak biokimia antar asam amino berdasarkan komposisi, polaritas, dan volume menjadi dasar penilaian *severity* perubahan. Studi terkini pada skala genom memanfaatkan basis data dbSNP [1] dan ClinVar untuk mengaitkan SNP dengan patogenitas, namun banyak *pipeline* produksi menyembunyikan langkah-langkah mendasar di balik *tooling* yang kompleks sehingga banyak orang sulit memahami konsep dasarnya.

1.1 Rumusan Masalah

Penelitian ini merumuskan lima pertanyaan: (i) bagaimana mendeteksi SNP secara akurat menggunakan *global alignment*; (ii) bagaimana mendeteksi ORF secara otomatis; (iii) bagaimana memprediksi dampak setiap SNP terhadap kodon dan protein; (iv) bagaimana mengintegrasikan *conservation scoring*, ClinVar, dan konteks regional untuk menilai patogenitas; (v) sejauh mana akurasi *pipeline* bertahan ketika densitas SNP meningkat?

1.2 Tujuan dan Kontribusi

Penelitian ini bertujuan (i) membangun *pipeline* komputasi end-to-end untuk mendeteksi SNP secara akurat; (2) melakukan deteksi ORF otomatis; (3) memprediksi dampak mutasi terhadap kodon dan protein; (4) menilai potensi patogenitas SNP menggunakan beberapa pendekatan biologis seperti *conservation scoring*, anotasi ClinVar, dan konteks regional genom; dan (5) mengevaluasi ketahanan performa *pipeline* terhadap peningkatan densitas mutasi pada sekuens DNA.

Kontribusi penelitian ini meliputi: (a) implementasi *pipeline* modular berbasis Python untuk analisis SNP; (b) integrasi ORF *auto-detection* untuk menentukan *reading frame* secara otomatis; (c) penerapan *conservation scoring* berbasis Grantham distance untuk menilai tingkat perubahan asam amino; (d) integrasi anotasi ClinVar dan klasifikasi *region*

genom; (e) pengembangan *pathogenicity scoring* terintegrasi; (f) validasi pada dataset sintetik (1.500 bp, 150 SNP) dan kasus biologis nyata HBB sickle-cell; serta (g) eksperimen sensitivitas pada berbagai densitas SNP untuk mengevaluasi stabilitas *pipeline*.

2. Metode

Pipeline dirancang modular, pemuatan FASTA, *alignment*, deteksi varian, deteksi ORF, klasifikasi dampak, *conservation scoring*, anotasi ClinVar, klasifikasi region, penilaian patogenitas, dan pelaporan klinis.

2.1 Pemuatan dan Validasi Sekuens. Fungsi `load_sequence` membaca file FASTA via Biopython SeqIO, mengubah karakter menjadi huruf kapital, dan memvalidasi terhadap himpunan {A, C, G, T, N}.

2.2 Sequence Alignment. *Alignment* dilakukan oleh Bio.Align.PairwiseAligner pada mode global dengan *parameter match* = +2, *mismatch* = -1, *open_gap* = -2, *extend_gap* = -1.

2.3 Deteksi Varian. Fungsi `detect_variants` mengiterasi kolom *alignment* secara sinkron. Tiga jenis varian dikenali: SNP (substitusi), INS (*gap* pada referensi), dan DEL (*gap* pada sampel).

2.4 Deteksi ORF. Modul mencari ORF terpanjang pada seluruh enam *reading frame*, yaitu tiga *frame* pada *strand forward* dan tiga *frame* pada *reverse complement*. Untuk setiap *frame*, algoritma mencari start codon (ATG), kemudian mentranslasi sekuens hingga menemukan stop codon (TAA, TAG, TGA) atau mencapai akhir sekuens. Setiap ORF yang ditemukan disimpan beserta informasi koordinat, panjang, dan *frame*-nya. ORF terpanjang kemudian dipilih sebagai dasar untuk klasifikasi dampak mutasi. Pendekatan ini membantu menentukan *reading frame* secara otomatis tanpa memerlukan anotasi eksternal, meskipun pada beberapa gen yang lebih kompleks masih diperlukan analisis tambahan untuk memastikan ORF yang paling representatif secara biologis. Modul juga mendukung tabel kodon standar (64 kodon, kode genetik universal) serta tabel kodon mitokondria vertebrata (kode genetik #2). Beberapa kodon memiliki fungsi berbeda dibanding kode genetik standar.

2.5 Klasifikasi Dampak Mutasi. Untuk tiap SNP pada posisi p , indeks kodon $k = \lfloor p/3 \rfloor$ dan

posisi dalam kodon $p \bmod 3$. Klasifikasi dampak tersebut, yaitu SILENT (asam amino sama), MISSENSE (berubah), NONSENSE (stop prematur), START_LOST, STOP_LOST, atau FRAMESHIFT.

2.6 Conservation Scoring. *Conservation scoring* menilai seberapa penting posisi tertentu pada genom berdasarkan tiga komponen. Komponen pertama adalah posisi dalam kodon: posisi ke-1 dan ke-2 lebih *conserved* (skor 1,0) dibanding posisi ke-3 (*wobble*, skor 0,3) karena redundansi kode genetik terletak pada posisi ketiga. Komponen kedua adalah Grantham distance [7], yaitu jarak biokimia antara asam amino referensi dan alternatif yang mengukur perbedaan komposisi, polaritas, dan volume molekul (range 0–215). Matriks lengkap 190 pasangan asam amino diimplementasikan dalam pipeline. Komponen ketiga adalah *impact severity*, klasifikasi NONSENSE mendapat skor 1,0, MISSENSE 0,7, dan SILENT 0,1. Ketiga komponen digabung dengan bobot 0,30:0,40:0,30 menjadi skor *conservation* tunggal (0,0 = benign, 1,0 = highly damaging). Pada implementasi produksi, skor ini biasanya digantikan oleh PhyloCSF atau GERP yang menggunakan multi-species alignment dari puluhan spesies vertebrata [8].

2.7 Anotasi ClinVar. Modul anotasi ClinVar melakukan lookup terhadap database varian klinis yang diketahui. Setiap entry berisi *variant_id*, nama gen, notasi HGVS pada level coding DNA dan protein, *clinical significance* (Pathogenic, Likely pathogenic, VUS, Likely benign, Benign), kondisi penyakit terkait, review status, frekuensi alel populasi, dan jumlah bukti pendukung. *Clinical significance* dikonversi ke skor numerik (Pathogenic=1,0; VUS=0,5; Benign=0,0), dan review status ke *confidence score* (*practice guideline*=1,0; *no assertion*=0,3). Pada implementasi ini, digunakan *simulated* ClinVar database yang berisi varian-varian terkenal termasuk HBB sickle-cell (CV000015333), hemoglobin C (CV000015334), β -thalassemia, serta varian BRCA1 dan TP53 untuk demonstrasi.

2.8 Klasifikasi Region. Posisi SNP diklasifikasi menjadi EXON_CODING (criticality 0,80), SPLICE_SITE (± 2 bp, criticality 0,95), INTRON (0,15), 5' UTR (0,40), 3' UTR (0,30), PROMOTER (0,35).

2.9 Penilaian Patogenisitas. Modul ini menggabungkan seluruh hasil analisis menjadi satu skor patogenisitas untuk memperkirakan

seberapa berbahaya suatu SNP terhadap organisme. Skor berada pada rentang 0,0 hingga 1,0 dengan nilai yang lebih tinggi menunjukkan potensi dampak biologis yang lebih serius. Perhitungan dilakukan menggunakan formula $\text{PathScore} = w_1 \times \text{ConservationScore} + w_2 \times \text{ClinVarSeverity} + w_3 \times \text{RegionCriticality} + w_4 \times \text{RarityBonus}$, dengan bobot default $w_1 = 0,35$; $w_2 = 0,35$; $w_3 = 0,20$; dan $w_4 = 0,10$. Penilaian dilakukan berdasarkan beberapa faktor, yaitu tingkat konservasi posisi gen, informasi klinis dari ClinVar, lokasi mutasi pada region genetik, serta kelangkaan varian pada populasi. Varian yang sangat jarang cenderung memperoleh skor lebih tinggi karena lebih berpotensi bersifat patogenik. Jika data ClinVar tidak tersedia, sistem akan menyesuaikan bobot penilaian dengan lebih mengutamakan *conservation scoring* dan konteks *region*. Berdasarkan skor akhir, SNP kemudian diklasifikasikan menjadi HIGH RISK, MODERATE RISK, LOW RISK, atau BENIGN, dan dilengkapi dengan tingkat *confidence* berdasarkan kualitas bukti yang tersedia pada data ClinVar.

2.10 Dataset. Dua sumber data digunakan dalam penelitian ini untuk mendukung proses validasi *pipeline*. Dataset pertama berupa sekuens sintetik sepanjang 1.500 bp (GC = 0,5, seed = 42) dengan 150 SNP acak yang digunakan sebagai ground truth untuk evaluasi akurasi deteksi. Dataset kedua berupa fragmen 60 bp ekson-1 gen HBB yang membandingkan kondisi *wild-type* dan *sickle-cell* untuk validasi pada kasus biologis nyata.

2.11 Metrik Evaluasi. Untuk mengukur performa *pipeline*, digunakan beberapa metrik evaluasi standar pada deteksi SNP, yaitu $\text{precision} = \text{TP}/(\text{TP}+\text{FP})$, $\text{recall} = \text{TP}/(\text{TP}+\text{FN})$, dan $\text{F1} = 2 \cdot \text{P} \cdot \text{R}/(\text{P}+\text{R})$. Dalam penelitian ini, setiap SNP diidentifikasi secara unik berdasarkan triple (posisi, REF, ALT).


3. Hasil dan Diskusi

3.1 Validasi pada Dataset Sintetik


Alignment Needleman–Wunsch pada sekuens sintetik (1.500 bp) menghasilkan alignment tanpa gap, konsisten karena sampel hanya berbeda berupa substitusi titik. Modul deteksi mengidentifikasi 150 SNP tanpa indel. ORF *auto-detection* berhasil menemukan reading frame konsisten. Evaluasi: Tabel 1.

Tabel 1. Evaluasi deteksi SNP pada dataset sintetik (1.500 bp, 150 SNP) vs. ground truth.


Metrik	Nilai
True Positive (TP)	150
False Positive (FP)	0
False Negative (FN)	0
Precision / Recall / F1	1,000 / 1,000 / 1,000



Gambar 2. Distribusi posisi 150 SNP pada sekuens sintetik 1.500 bp. Warna menunjukkan kategori dampak.




Gambar 3. Kiri: distribusi kategori dampak mutasi. Kanan: matriks substitusi REF → ALT.



Gambar 4. Kiri: conservation score per kategori dampak. Tengah: distribusi pathogenicity score. Kanan: Grantham distance vs pathogenicity score.

3.2 Validasi pada Kasus Biologis Nyata: HBB

Pada fragmen 60 bp gen HBB, *pipeline* berhasil mendeteksi tepat satu SNP, yaitu perubahan A→T pada posisi 19 (0-based) yang berada pada kodon ke-7. Hasil translasi menunjukkan perubahan GAG→GTG (Glu→Val) yang diklasifikasikan sebagai mutasi MISSENSE dan identik dengan mutasi *sickle-cell* yang dilaporkan oleh Ingram [5]. Selain mendeteksi mutasi, *pipeline* juga melakukan analisis klinis tambahan yang menunjukkan *conservation score* sebesar 0,735, ClinVar match CV000015333 dengan status Pathogenic, region EXON_CODING, serta *pathogenicity score* sebesar 0,787 yang dikategorikan sebagai MODERATE RISK dengan confidence HIGH.




Gambar 5. Hasil pipeline pada fragmen HBB. Kiri: posisi SNP. Kanan: kategori dampak (MISSENSE tunggal).

3.3 Eksperimen Sensitivitas terhadap Densitas Mutasi

Untuk mengevaluasi ketahanan performa *pipeline* terhadap peningkatan jumlah mutasi, dilakukan lima trial independen pada delapan tingkat densitas SNP menggunakan sekuens referensi sepanjang 1.500 bp. Hasil pengujian kemudian dirangkum pada Tabel 2 dan divisualisasikan pada Gambar 5.

Tabel 2. Hasil eksperimen sensitivitas ($n=5$ trial; ref 1.500 bp). Format: mean (sd).

Densitas (%)	Precision	Recall	F1
1,00	1,000 (,000)	1,000 (,000)	1,000 (,000)
2,00	1,000 (,000)	1,000 (,000)	1,000 (,000)
3,33	1,000 (,000)	1,000 (,000)	1,000 (,000)
6,67	1,000 (,000)	0,988 (,016)	0,994 (,008)
13,33	0,999 (,002)	0,993 (,010)	0,996 (,006)
20,00	0,997 (,005)	0,958 (,028)	0,977 (,016)
26,67	0,970 (,014)	0,840 (,020)	0,900 (,015)
33,33	0,953 (,034)	0,773 (,067)	0,853 (,054)



Gambar 6. *Sensitivitas pipeline terhadap densitas SNP. F1 $\geq 0,97$ hingga 20%; recall turun di densitas tinggi karena aligner memilih gap.*

Pipeline mempertahankan akurasi yang baik hingga 3,33%. Pada densitas $\geq 6,67\%$, recall mulai turun, sedangkan precision tetap tinggi. Pada 33,33%, F1 turun ke 0,853 - sekitar 23% SNP terlewat karena *aligner* memilih gap daripada mismatch berturut-turut.

3.4 Analisis Conservation dan Patogenisitas

MISSENSE mutations memiliki conservation score lebih tinggi daripada SILENT karena perubahan pada posisi 1–2 kodon dengan Grantham distance signifikan. NONSENSE mendapat skor tertinggi. Korelasi positif antara Grantham distance dan pathogenicity score mengkonfirmasi scoring function menangkap severity biokimia.

Kasus HBB memberikan validasi biologis sangat kuat dimana *pipeline* mendeteksi tepat satu SNP dan mengklasifikasikannya sebagai missense Glu→Val, yang sama persis dengan mutasi penyebab hemoglobin S. Substitusi Val pada permukaan rantai β -globin menciptakan hydrophobic patch yang memicu polimerisasi dalam kondisi rendah oksigen, mengakibatkan eritrosit berbentuk sabit. Pathogenicity score 0,787 dengan confidence high mengkonfirmasi signifikansi klinis mutasi ini. Grantham distance Glu→Val = 121 menandakan perubahan dari asam amino bermuatan negatif (hidrofil) ke nonpolar (hidrofob), konsisten dengan mekanisme patologis yang diketahui.

Distribusi kategori dampak pada dataset sintetik bersifat instructive artinya mayoritas SNP menghasilkan MISSENSE, mencerminkan struktur kode genetik standar di mana hanya posisi ketiga kodon yang umumnya degenerate. Rata-rata pathogenicity score untuk MISSENSE (0,665) secara signifikan lebih tinggi daripada SILENT (0,379), sementara NONSENSE mencapai 0,872 atau mendekati skor maksimum, menunjukkan scoring function berhasil menangkap hierarchy dampak biologis.

Dari sisi sensitivitas, penurunan recall pada densitas tinggi ($\geq 20\%$) dinilai wajar menggunakan Needleman-Wunsch dengan skema match=+2, mismatch=-1, gap_open=-2 kadang memilih satu match + gap daripada dua mismatch berturut-turut, karena $(+2) + (-2) = 0 > (-1) + (-1) = -2$. Akibatnya, SNP yang berdekatan dapat tersembunyi sebagai pasangan

INS+DEL. Skema skoring dengan penalti gap lebih ketat (open_gap = -5) atau penggunaan matriks substitusi transisi/transversi (Ti/Tv) yang membedakan jenis substitusi dapat memperbaiki recall pada densitas tinggi tanpa mengorbankan precision.

4. Kesimpulan dan Saran

Pipeline yang dikembangkan pada penelitian ini berhasil mendeteksi SNP secara akurat menggunakan global alignment berbasis Needleman-Wunsch, dengan hasil precision, recall, dan F1-score sebesar 1,000 pada dataset sintetik 1.500 bp dengan 150 SNP. Sistem juga berhasil melakukan ORF auto-detection untuk menentukan reading frame yang sesuai tanpa anotasi eksternal sehingga klasifikasi dampak mutasi dapat dilakukan secara otomatis. Selain mendeteksi SNP, *pipeline* mampu memprediksi dampak mutasi terhadap kodon dan protein dan mengintegrasikan conservation scoring, anotasi ClinVar, dan konteks region genomik untuk memperkirakan tingkat patogenisitas suatu varian. Pada kasus biologis nyata gen HBB, *pipeline* berhasil mengidentifikasi mutasi sickle-cell Glu→Val dengan pathogenicity score sebesar 0,787 yang termasuk kategori MODERATE RISK dengan confidence HIGH. Pengujian sensitivitas pada delapan tingkat densitas SNP juga menunjukkan bahwa *pipeline* mempertahankan performa yang baik dengan nilai F1 $\geq 0,97$ hingga densitas mutasi 20%, meskipun recall mulai menurun pada densitas yang lebih tinggi akibat karakteristik alignment berbasis gap. Secara keseluruhan, hasil penelitian menunjukkan bahwa pendekatan yang dikembangkan mampu menghubungkan konsep biologi dan komputasi secara efektif untuk analisis SNP dan interpretasi dampak biologisnya, meskipun masih terdapat beberapa keterbatasan pada skalabilitas dan kompleksitas data biologis nyata yang dapat dikembangkan lebih lanjut pada penelitian berikutnya.

Saran penelitian lanjutan (1) integrasi ClinVar API nyata untuk anotasi real-time; (2) integrasi PhyloCSF/GERP untuk conservation score berbasis multi-species alignment; (3) parsing GFF/GTF untuk anotasi gen otomatis dari Ensembl/RefSeq; (4) machine learning classifier untuk prediksi patogenisitas dari fitur yang sudah dibangun; (5) ekstensi ke deteksi varian struktural (inversi, duplikasi, CNV); (6) output VCF standar untuk interoperabilitas dengan tools bioinformatika lain; (7) optimisasi

ke implementasi linear-space (Hirschberg) atau seed-and-extend untuk skalabilitas genom utuh.

5. Kontribusi Anggota

Tabel 3. Kontribusi Tiap Anggota

Anggota	Tugas
Surya Suharna 18223075	- Mengerjakan <i>pipeline notebook</i> - Mengerjakan sistem <i>frontend</i> dan <i>backend</i>
Muhammad Faiz Alfikrona, 18223009	- Mengerjakan fitur analisis klinis dan integrasi ClinVar. - Menambahkan <i>workflow readiness project</i>.
Ni Made Sekar Jelita, 18223101	- Melakukan analisis konsep SNP Detection - Menulis laporan - Membuat powerpoint

6. Tautan Pengerjaan

Tabel 4. Tautan Deliverable

Deliverable	Tautan
Repository	https://github.com/suryasuharna23/SNP-Detection-Komputasi-Domain-Spesifik
Notebook	https://colab.research.google.com/drive/1IWFOs9Cj8Sur73hPa0CtX1PHS_XsS7m?usp=sharing
YouTube	https://youtu.be/OK589iKPvdE?si=AMRyYTzIwKMECjIz

Daftar Pustaka

- [1] S. T. Sherry et al., “dbSNP: the NCBI database of genetic variation,” *Nucleic Acids Res.*, vol. 29, no. 1, hlm. 308–311, 2001.
- [2] D. W. Mount, *Bioinformatics: Sequence and Genome Analysis*, 2nd ed. CSHL Press, 2004.
- [3] S. B. Needleman dan C. D. Wunsch, “A general method applicable to the search for similarities in the amino acid sequence of two proteins,” *J. Mol. Biol.*, vol. 48, no. 3, hlm. 443–453, 1970.
- [4] P. J. A. Cock et al., “Biopython: freely available Python tools for computational molecular biology,”

Bioinformatics, vol. 25, no. 11, hlm. 1422–1423, 2009.

[5] V. M. Ingram, “Gene mutations in human haemoglobin,” *Nature*, vol. 180, hlm. 326–328, 1957.

[6] M. J. Landrum et al., “ClinVar: improvements to accessing data,” *Nucleic Acids Res.*, vol. 48, no. D1, hlm. D835–D844, 2020.

[7] R. Grantham, “Amino acid difference formula to help explain protein evolution,” *Science*, vol. 185, hlm. 862–864, 1974.

[8] K. S. Pollard et al., “Detection of nonneutral substitution rates on mammalian phylogenies,” *Genome Res.*, vol. 20, no. 1, hlm. 110–121, 2010.

[9] T. F. Smith dan M. S. Waterman, “Identification of common molecular subsequences,” *J. Mol. Biol.*, vol. 147, hlm. 195–197, 1981.

[10] H. Li, “Minimap2: pairwise alignment for nucleotide sequences,” *Bioinformatics*, vol. 34, no. 18, hlm. 3094–3100, 2018.