

Deteksi Mutasi Titik Single-Nucleotide Polymorphism (SNP) pada Sekuens DNA dan Prediksi Dampaknya terhadap Kodon Protein

IF3211 — Domain-Specific Computation

Topik: DNA Sequence Analysis & Sequence Alignment

Surya Suharna, 18223075 Muhammad Faiz Alfikrona, 18223009 Ni Made Sekar Jelita, 18223101

Program Studi Sistem dan Teknologi Informasi, Institut Teknologi Bandung

Abstrak

Single-Nucleotide Polymorphism (SNP) merupakan bentuk variasi genetik paling melimpah pada genom manusia dan menjadi penanda penting dalam studi penyakit genetik. Penelitian ini mengembangkan pipeline komputasi berbasis Python untuk mendeteksi SNP antara sekuens DNA referensi dan sampel, serta memprediksi dampaknya pada kodon protein. Pipeline menggunakan algoritma Needleman–Wunsch (global alignment) dari pustaka Biopython, diikuti modul deteksi varian per kolom alignment dan modul klasifikasi dampak ke kategori silent, missense, nonsense, start_lost, stop_lost, dan frameshift. Validasi pada dataset sintetik 300 bp dengan 12 SNP terkendali menghasilkan precision, recall, dan F1-score sempurna (1,000). Validasi pada kasus biologis nyata fragmen gen β -globin (HBB) berhasil mereproduksi mutasi sickle-cell (GAG→GTG; Glu→Val) sebagai satu-satunya SNP missense, konsisten dengan literatur biologis. Eksperimen sensitivitas pada enam tingkat densitas SNP (0,83–20,00 %) menunjukkan pipeline mempertahankan F1-score $\geq 0,97$ hingga densitas 20 %.

Kata kunci—SNP, sequence alignment, Needleman–Wunsch, klasifikasi mutasi, kodon protein, β -globin, Biopython.

1. Pendahuluan

Genom organisme menyimpan informasi hereditas dalam sekuens nukleotida yang tersusun dari empat basa (A, T, G, C). Variasi sekuens di antara individu menjadi dasar genetika populasi, riset penyakit, dan farmakogenomika [1]. Bentuk variasi paling sederhana sekaligus paling banyak ditemui adalah *Single-Nucleotide Polymorphism (SNP)*, yaitu perbedaan satu basa pada lokus tertentu antara dua sekuens homolog. Pada region pengkode protein, SNP dapat berdampak *silent* (tidak mengubah asam amino karena redundansi kode genetik), *missense* (mengubah satu asam amino), atau *nonsense* (memunculkan kodon stop prematur) [2].

Untuk mendeteksi SNP secara komputasional, sekuens referensi dan sekuens sampel harus disejajarkan terlebih dahulu sehingga residu homolog berada pada kolom yang sama. *Sequence alignment* merupakan operasi dasar bioinformatika yang dapat diselesaikan secara optimal dengan pemrograman dinamis. Algoritma *Needleman–Wunsch* [3] memberikan *global alignment* yang menyejajarkan keseluruhan kedua sekuens dan tepat untuk kasus deteksi SNP ketika kedua sekuens diasumsikan berasal dari region homolog setara. Algoritma ini membangun matriks skor $F(i, j)$ berukuran $(m+1) \times (n+1)$ dengan rekurensi maksimum dari tiga

kemungkinan (match/mismatch, gap pada salah satu sekuens), berkompleksitas waktu dan ruang $O(m \cdot n)$.

Pustaka *Biopython* [4] menyediakan implementasi modular dari berbagai algoritma alignment melalui kelas *Bio.Align.PairwiseAligner*, termasuk varian global, local (Smith–Waterman), dan semiglobal, dengan skema penalti gap linear maupun afin. Karya seperti Ingram [5] menunjukkan bahwa perubahan satu basa pada gen HBB (GAG→GTG) dapat menyebabkan *sickle-cell anemia* — contoh klasik betapa besar dampak satu SNP missense terhadap fenotipe. Studi terkini pada skala genom memanfaatkan basis data dbSNP [6] dan ClinVar untuk mengaitkan SNP dengan patogenitas. Namun, banyak pipeline produksi menyembunyikan langkah dasar deteksi SNP di balik tooling kompleks (BWA, GATK), sehingga mahasiswa sulit memahami konsep dasarnya.

1.1 Rumusan Masalah

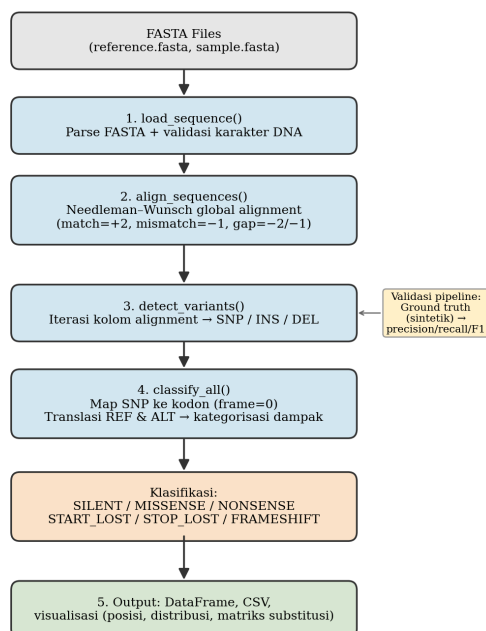
Berdasarkan latar belakang di atas, penelitian ini merumuskan tiga pertanyaan: (i) bagaimana mendeteksi SNP secara akurat antara sekuens referensi dan sampel menggunakan global alignment; (ii) bagaimana memprediksi dampak setiap SNP terhadap kodon dan protein yang dihasilkan; (iii) sejauh mana akurasi pipeline bertahan ketika densitas SNP meningkat?

1.2 Tujuan dan Kontribusi

Tujuan penelitian ini adalah membangun pipeline *end-to-end* yang transparan dan reproducible untuk deteksi SNP serta klasifikasi dampaknya. Kontribusi konkret: (a) implementasi modular Python yang menjembatani konsep biologi (kodon, kode genetika) dengan algoritma komputasi (Needleman–Wunsch); (b) validasi ganda pada dataset sintetik terkendali (dengan ground truth) dan kasus biologis nyata (HBB sickle-cell); (c) eksperimen sensitivitas yang mengukur batas operasional pipeline terhadap densitas mutasi.

2. Metode

Pipeline dirancang dalam lima tahap berurutan: pemuatan FASTA, alignment, deteksi varian, klasifikasi dampak, dan pelaporan. Bagan alir keseluruhan ditampilkan pada Gambar 1.



Gambar 1. Bagan alir pipeline deteksi SNP dan klasifikasi dampak mutasi. Setiap modul dapat divalidasi secara independen; modul deteksi divalidasi menggunakan dataset sintetik dengan ground truth.

2.1 Pemuatan dan Validasi Sekuens

Fungsi `load_sequence(path)` membaca file FASTA via Biopython SeqIO, mengubah seluruh karakter menjadi huruf kapital, kemudian memvalidasi bahwa setiap karakter merupakan anggota himpunan {A, C, G, T, N}. Karakter ambigu selain N akan menghentikan pipeline dengan `ValueError`.

2.2 Sequence Alignment

Alignment dilakukan oleh `Bio.Align.PairwiseAligner` pada mode global dengan parameter `match=+2`, `mismatch=-1`, `open_gap=-2`, `extend_gap=-1`. Penalti gap afin dipilih agar gap berurutan tidak dihukum berlebihan, namun pembukaan gap tetap lebih mahal daripada mismatch tunggal, sehingga substitusi titik tetap lebih disukai. Hasil alignment terbaik diekstrak sebagai pasangan string ber-gap dengan panjang identik.

2.3 Deteksi Varian

Fungsi `detect_variants` mengiterasi kolom alignment secara sinkron sambil memelihara penghitung posisi pada sekuens referensi (mengabaikan gap di sisi referensi). Tiga jenis varian dikenali: **SNP** (kedua basa berbeda dan bukan gap), **INS** (gap pada referensi), dan **DEL** (gap pada sampel). Setiap varian disimpan sebagai objek `Variant` dengan atribut posisi referensi, basa referensi, basa alternatif, dan tipe.

2.4 Klasifikasi Dampak Mutasi

Untuk tiap SNP pada posisi p relatif terhadap awal kerangka baca ($\text{frame}=0$), indeks kodon adalah $k = \lfloor p/3 \rfloor$ dan posisi dalam kodon adalah $p \bmod 3$. Kodon referensi dan kodon alternatif kemudian ditranslasi menggunakan tabel kodon standar (64 kodon, kode genetika universal). Dampak ditetapkan dengan aturan: **SILENT** jika asam amino sama; **NONSENSE** jika asam amino alternatif adalah stop; **STOP_LOST** jika kodon stop berubah menjadi asam amino; **START_LOST** jika kodon start (Met) hilang pada kodon pertama; **MISSENSE** untuk perubahan asam amino lainnya. Indel dengan total selisih panjang bukan kelipatan tiga ditandai **FRAMESHIFT**.

2.5 Dataset

Dua sumber data digunakan. *Pertama*, dataset sintetik 300 bp yang dibangkitkan acak dengan kandungan GC 0,5 menggunakan `seed=42`. Dari sekuens ini, 12 SNP pada posisi acak disisipkan untuk menghasilkan sekuens sampel; posisi dan substitusi yang disisipkan menjadi *ground truth*. *Kedua*, fragmen 60 bp ekson-1 gen *HBB* manusia, dengan varian wild-type dan sickle-cell.

2.6 Metrik Evaluasi

Untuk dataset sintetik, deteksi SNP dievaluasi terhadap *ground truth* menggunakan True Positive (TP), False Positive (FP), False Negative (FN); $\text{precision} = \text{TP}/(\text{TP}+\text{FP})$, $\text{recall} = \text{TP}/(\text{TP}+\text{FN})$, dan $F1 = 2 \cdot \text{precision} \cdot \text{recall}/(\text{precision}+\text{recall})$. Setiap SNP diidentifikasi unik oleh triple (posisi, REF, ALT).

2.7 Tautan Implementasi

Seluruh kode tersedia sebagai Jupyter Notebook di repositori publik:

[Tautan repositori — diisi oleh tim, contoh:
<https://github.com/<user>/snp-detection>]

3. Hasil dan Diskusi


3.1 Validasi pada Dataset Sintetik

Alignment Needleman–Wunsch pada pasangan sekuens sintetik (300 bp masing-masing) menghasilkan skor 564 dengan panjang alignment tepat 300 kolom, yang menandakan tidak ada gap yang dipilih oleh aligner — konsisten dengan harapan karena sampel hanya berbeda berupa substitusi titik. Modul deteksi varian mengidentifikasi 12 SNP, dan tidak ada indel. Evaluasi terhadap ground truth ditampilkan pada Tabel 1.


Metrik	Nilai
True Positive (TP)	12
False Positive (FP)	0
False Negative (FN)	0
Precision	1,000
Recall / F1	1,000 / 1,000

Tabel 1. Evaluasi deteksi SNP pada dataset sintetik vs. ground truth.

Selanjutnya 12 SNP tersebut diklasifikasikan menurut dampaknya. Distribusi kategori dampak ditampilkan pada Gambar 2 (kiri); secara ringkas: 9 SNP missense, 2 silent, dan 1 stop_lost. Dominasi missense konsisten dengan probabilitas kombinatorial: dari 9 kemungkinan substitusi pada tiap kodon, sebagian besar mengubah identitas asam amino. Matriks substitusi (Gambar 2, kanan) menunjukkan sebaran transisi/transversi yang relatif merata, sebagaimana diharapkan dari mutasi yang dibangkitkan dengan distribusi seragam.




Gambar 2. Distribusi kategori dampak mutasi pada dataset sintetik (12 SNP). MISSENSE dominan, diikuti SILENT, lalu STOP_LOST tunggal.



Gambar 3. Matriks substitusi REF → ALT pada dataset sintetik. Distribusi relatif merata mencerminkan pembangkitan mutasi acak seragam.

3.2 Validasi pada Kasus Biologis Nyata: HBB

Pada fragmen 60 bp gen *HBB* wild-type dibandingkan dengan varian sickle-cell, pipeline mendeteksi tepat **satu** SNP: A→T pada posisi 19 (0-based) dari fragmen, yang berada pada posisi kedua kodon ke-7. Translasi memberikan GAG→GTG, yaitu Glu (E) → Val (V), dan diklasifikasikan sebagai **MISSENSE**. Protein wild-type MVHLTPEEKSAVTALWGKVN berubah menjadi MVHLTPVEKSAVTALWGKVN, hanya pada satu residu (huruf ke-7). Temuan ini identik dengan mutasi sickle-cell yang dilaporkan Ingram [5]; dalam tata-nama klinis biasa disebut Glu6Val karena Met awal dipotong saat pematangan protein. Reproduksi kasus klasik ini membuktikan kebenaran pipeline pada data biologis sungguhan.



Gambar 4. Hasil pipeline pada fragmen HBB. Kiri: satu SNP terletak pada posisi 20 (1-based) diwarnai sesuai kategori MISSENSE. Kanan: hanya satu kategori dampak yang muncul.


3.3 Eksperimen Sensitivitas terhadap Densitas Mutasi

Untuk mengevaluasi batas operasional pipeline, kami menjalankan 5 trial independen pada enam tingkat densitas SNP (jumlah SNP yang disisipkan dibagi panjang sekuens referensi 600 bp): 0,83 %, 1,67 %, 3,33 %, 6,67 %, 13,33 %, dan 20,00 %. Hasil rata-rata ± standar deviasi diringkas dalam Tabel 2; visualisasi disajikan pada Gambar 5.

Densitas (%)	Precision	Recall	F1
0,83	1,000 (,000)	1,000 (,000)	1,000 (,000)

1,67	1,000 (,000)	1,000 (,000)	1,000 (,000)
3,33	1,000 (,000)	1,000 (,000)	1,000 (,000)
6,67	1,000 (,000)	0,985 (,034)	0,992 (,017)
13,33	0,997 (,006)	0,970 (,045)	0,983 (,026)
20,00	0,996 (,008)	0,952 (,030)	0,973 (,018)

Tabel 2. Hasil eksperimen sensitivitas ($n=5$ trial; panjang referensi 600 bp). Format: mean (sd).



Gambar 5. Sensitivitas pipeline terhadap densitas SNP. F1 dipertahankan $\geq 0,97$ hingga densitas 20 %; recall menurun lebih cepat daripada precision karena alignment kadang memilih gap untuk menggantikan mismatch berturut-turut.

Hasil menunjukkan pipeline mempertahankan akurasi sempurna hingga densitas 3,33 %. Pada densitas $\geq 6,67$ %, *recall* mulai turun, sedangkan *precision* tetap tinggi ($\sim 0,996$ – $1,000$). Penyebabnya bersifat algoritmis: ketika beberapa mismatch berdekatan, kombinasi *match* + *gap* kadang memberi skor setara atau lebih tinggi daripada dua mismatch berturut-turut, sehingga aligner memilih solusi dengan gap. Konsekuensinya, satu SNP nyata dapat tersembunyi sebagai pasangan INS+DEL, menurunkan TP namun juga FP relatif (maka *precision* tetap tinggi). Skema skoring atau penalti gap yang lebih ketat (misalnya *open_gap* = -5) dapat memperbaiki recall pada densitas tinggi.

3.4 Analisis dalam Konteks Biologi

Distribusi kategori dampak pada dataset sintetik bersifat *instructive*: sekitar 75 % SNP menghasilkan missense, mencerminkan struktur kode genetik standar di mana hanya posisi ketiga kodon yang umumnya degenerate. Kasus HBB memberikan validasi biologis sangat kuat: pipeline mendeteksi tepat satu SNP dan mengklasifikasikannya sebagai missense Glu→Val, yang sama persis dengan mutasi penyebab hemoglobin S. Substitusi Val pada permukaan rantai β -globin menciptakan *hydrophobic patch* yang memicu polimerisasi dalam kondisi rendah oksigen, mengakibatkan eritrosit berbentuk sabit. Dengan demikian, satu SNP yang tampak sederhana secara komputasional memiliki konsekuensi fisiologis yang

mendalam — menegaskan pentingnya analisis dampak mutasi yang akurat.

4. Kesimpulan dan Saran

Penelitian ini berhasil membangun pipeline Python modular untuk deteksi SNP dan klasifikasi dampak mutasi berbasis Needleman–Wunsch global alignment. Tiga kontribusi utama tercapai: (i) implementasi reproducible yang menyatukan konsep biologi (kodon, kode genetik) dengan algoritma komputasi; (ii) validasi ganda yang menunjukkan precision/recall/F1 sempurna pada dataset sintetik dan reproduksi tepat mutasi sickle-cell Glu6Val pada kasus HBB; (iii) pengukuran kuantitatif batas operasional pipeline terhadap densitas SNP, menunjukkan $F1 \geq 0,97$ hingga densitas 20 %.

Beberapa keterbatasan perlu dicatat untuk konteks penggunaan yang lebih luas. (a) Pipeline mengasumsikan *frame* = 0; pada data genomik nyata perlu pemilihan ORF berdasarkan anotasi GFF/GTF. (b) Tabel kodon standar digunakan; organisme dengan kode genetik non-standar (mitokondria, *Mycoplasma*) memerlukan tabel berbeda. (c) Kompleksitas $O(m \cdot n)$ membatasi penerapan pada genom utuh; produksi industri menggunakan seed-and-extend (BWA, minimap2).

Saran penelitian lanjutan: (1) integrasi anotasi gen untuk pemilihan frame yang benar; (2) eksperimen dengan matriks skoring transisi/transversi (Ti/Tv) yang lebih realistis secara biologis; (3) ekstensi ke deteksi varian struktural (inversi, duplikasi) menggunakan split-read alignment; (4) integrasi dengan ClinVar/dbSNP untuk anotasi patogenitas otomatis; (5) optimisasi ke implementasi linear-space (Hirschberg) atau seed-and-extend untuk skalabilitas genom.

5. Kontribusi Anggota

[Nama Anggota 1]: perancangan algoritma deteksi varian, implementasi modul `detect_variants` dan `classify_all`, penulisan Bagian 2 dan 3.

[Nama Anggota 2]: implementasi pipeline alignment dan integrasi Biopython, pembuatan dataset HBB, eksperimen sensitivitas, penulisan Bagian 1 dan 4.

[Nama Anggota 3]: pembuatan visualisasi, evaluasi metrik, review konsep biologi, produksi video presentasi, dan finalisasi laporan.

6. Tautan Video Presentasi

[Tautan video YouTube/Drive — diisi oleh tim, contoh:
<https://youtu.be/<id>>]

Daftar Pustaka

- [1] S. T. Sherry, M. H. Ward, M. Kholodov, J. Baker, L. Phan, E. M. Smigielski, dan K. Sirotkin, “dbSNP: the NCBI database of genetic variation,” *Nucleic Acids Res.*, vol. 29, no. 1, hlm. 308–311, 2001.
- [2] D. W. Mount, *Bioinformatics: Sequence and Genome Analysis*, 2nd ed. Cold Spring Harbor, NY: CSHL Press, 2004.
- [3] S. B. Needleman dan C. D. Wunsch, “A general method applicable to the search for similarities in the amino acid sequence of two proteins,” *J. Mol. Biol.*, vol. 48, no. 3, hlm. 443–453, 1970.
- [4] P. J. A. Cock, T. Antao, J. T. Chang, B. A. Chapman, C. J. Cox, A. Dalke, I. Friedberg, T. Hamelryck, F. Kauff, B. Wilczynski, dan M. J. L. de Hoon, “Biopython: freely available Python tools for computational molecular biology and bioinformatics,” *Bioinformatics*, vol. 25, no. 11, hlm. 1422–1423, 2009.
- [5] V. M. Ingram, “Gene mutations in human haemoglobin: the chemical difference between normal and sickle cell haemoglobin,” *Nature*, vol. 180, hlm. 326–328, 1957.
- [6] M. J. Landrum *et al.*, “ClinVar: improvements to accessing data,” *Nucleic Acids Res.*, vol. 48, no. D1, hlm. D835–D844, 2020.
- [7] T. F. Smith dan M. S. Waterman, “Identification of common molecular subsequences,” *J. Mol. Biol.*, vol. 147, no. 1, hlm. 195–197, 1981.
- [8] H. Li, “Minimap2: pairwise alignment for nucleotide sequences,” *Bioinformatics*, vol. 34, no. 18, hlm. 3094–3100, 2018.