

Deteksi Mutasi Titik Single-Nucleotide Polymorphism (SNP) pada Sekuens DNA, Prediksi Dampak terhadap Kodon Protein

IF3211 Domain-Specific Computation

Topik: DNA Sequence Analysis & Sequence Alignment

Surya Suharna, 18223075 Muhammad Faiz Alfikrona, 18223009 Ni Made Sekar Jelita, 18223101

Program Studi Sistem dan Teknologi Informasi, Institut Teknologi Bandung

Abstrak

Single-Nucleotide Polymorphism (SNP) merupakan bentuk variasi genetik paling melimpah pada genom manusia. Penelitian ini mengembangkan *pipeline* komputasi berbasis Python untuk mendeteksi SNP antara sekuens DNA referensi dan sampel, memprediksi dampaknya pada kodon protein, serta menilai patogenisitas klinis. *Pipeline* menggunakan algoritma Needleman-Wunsch (*global alignment*) dari Biopython, diikuti modul deteksi ORF pada enam *reading frame*, klasifikasi dampak mutasi (*silent*, *missense*, *nonsense*, *start lost*, *stop lost*, *frameshift*), *conservation scoring* berbasis Grantham distance, anotasi ClinVar, klasifikasi region genomik, dan penilaian patogenisitas (skor 0–1). Validasi pada dataset sintetik 1.500 bp dengan 150 SNP menghasilkan *precision*, *recall*, dan *F1-score* sempurna (1,000). Validasi pada fragmen gen β -globin (HBB) berhasil mereproduksi mutasi *sickle-cell* (GAG→GTG; Glu→Val) dengan *pathogenicity score* 0,787 dan *confidence high*. Eksperimen sensitivitas pada delapan tingkat densitas SNP (1,0–33,3%) menunjukkan $F1 \geq 0,97$ hingga densitas 20%.


Kata kunci: SNP, Needleman–Wunsch, Grantham distance, ClinVar, patogenisitas, β -globin, Biopython.

1. Pendahuluan

Genom organisme menyimpan informasi hereditas dalam sekuens nukleotida yang tersusun dari empat basa (A, T, G, C). Variasi sekuens di antara individu menjadi dasar genetika populasi, riset penyakit, dan farmakogenomika [1]. Bentuk variasi paling sederhana adalah *Single-Nucleotide Polymorphism (SNP)*, yaitu perbedaan satu basa pada lokus tertentu antara dua sekuens homolog. Pada region pengkode protein, SNP dapat berdampak *silent*, *missense*, atau *nonsense* [2].

Algoritma *Needleman–Wunsch* [3] memberikan *global alignment* optimal dengan pemrograman dinamis berkompleksitas $O(m \cdot n)$. Algoritma ini membangun matriks skor $F(i, j)$ berukuran $(m + 1) \times (n + 1)$, di mana setiap sel dihitung sebagai maksimum dari tiga kemungkinan: *match/mismatch* dari diagonal, *gap* pada sekuens pertama, atau *gap* pada sekuens kedua. *Traceback* dari pojok kanan bawah memberikan *alignment* optimal. Pustaka *Biopython* [4] menyediakan implementasinya melalui kelas `Bio.Align.PairwiseAligner` dengan berbagai opsi penalti *gap* (linear maupun afin). Karya Ingram [5] menunjukkan bahwa satu perubahan basa pada gen HBB (GAG→GTG) menyebabkan *sickle-cell anemia*, di mana substitusi asam amino Glu→Val pada posisi ke-6 protein β -globin matang menciptakan *hydrophobic patch* pada permukaan molekul hemoglobin yang memicu polimerisasi dalam kondisi rendah oksigen.

Hydrophobic Intensity Patch (hi-patch)



Gambar 1.1 *Hydrophobic Intensity Patch*

(<https://github.com/hector-s-m/hi-patch>)

Namun, mendeteksi SNP saja tidak cukup, pertanyaan kritis selanjutnya adalah apakah SNP tersebut berbahaya bagi organisme. Untuk menjawab hal ini, diperlukan beberapa analisis tambahan. Pertama, analisis *conservation*: posisi yang terkonservasi kuat di banyak spesies cenderung penting secara fungsional, sehingga mutasi pada posisi tersebut lebih mungkin merusak. Kedua, anotasi ClinVar [6] yang mengumpulkan bukti klinis tentang varian genetik dari laboratorium di seluruh dunia. Ketiga, konteks regional: SNP pada *exon coding* lebih berdampak daripada pada *intron*, kecuali jika berada di *splice site*. Keempat, Grantham [7] mengembangkan matriks jarak biokimia antar asam amino berdasarkan komposisi, polaritas, dan volume menjadi dasar penilaian *severity* perubahan. Studi terkini pada skala genom memanfaatkan basis data dbSNP [1] dan ClinVar untuk mengaitkan SNP dengan patogenitas, namun banyak *pipeline* produksi menyembunyikan langkah dasar di balik *tooling* kompleks sehingga mahasiswa sulit memahami konsep dasarnya.

1.1 Rumusan Masalah

Penelitian ini merumuskan lima pertanyaan: (i) bagaimana mendeteksi SNP secara akurat menggunakan *global alignment*; (ii) bagaimana mendeteksi ORF secara otomatis; (iii) bagaimana memprediksi dampak setiap SNP terhadap kodon dan protein; (iv) bagaimana mengintegrasikan *conservation scoring*, ClinVar, dan konteks regional untuk menilai patogenisitas; (v) sejauh mana akurasi pipeline bertahan ketika densitas SNP meningkat?

1.2 Tujuan dan Kontribusi

Tujuan penelitian: pipeline *end-to-end* untuk deteksi SNP, klasifikasi dampak, dan penilaian patogenisitas. Kontribusi: (a) implementasi modular Python; (b) ORF auto-detection; (c) *conservation scoring* berbasis Grantham *distance*; (d) anotasi ClinVar dan klasifikasi region; (e) *pathogenicity scoring* terintegrasi; (f) validasi pada dataset sintetik (1.500 bp, 150 SNP) dan HBB *sickle-cell*; (g) eksperimen sensitivitas pada delapan densitas.

2. Metode

Pipeline dirancang modular, pemuatan FASTA, *alignment*, deteksi varian, deteksi ORF, klasifikasi dampak, *conservation scoring*, anotasi ClinVar, klasifikasi region, penilaian patogenisitas, dan pelaporan klinis.

2.1 Pemuatan dan Validasi Sekuens. Fungsi `load_sequence` membaca file FASTA via Biopython SeqIO, mengubah karakter menjadi huruf kapital, dan memvalidasi terhadap himpunan {A, C, G, T, N}.

2.2 Sequence Alignment. *Alignment* dilakukan oleh Bio.Align.PairwiseAligner pada mode global dengan *parameter match* = +2, *mismatch* = -1, *open_gap* = -2, *extend_gap* = -1.

2.3 Deteksi Varian. Fungsi `detect_variants` mengiterasi kolom *alignment* secara sinkron. Tiga jenis varian dikenali: SNP (substitusi), INS (gap pada referensi), dan DEL (gap pada sampel).

2.4 Deteksi ORF. Modul mencari ORF terpanjang di semua enam *reading frame* (tiga *forward*, tiga *reverse complement*). Untuk setiap *frame* dan *strand*, algoritma mencari *start codon* (ATG), mentranslasi hingga *stop codon* (TAA, TAG, TGA) atau akhir sekuens, dan menyimpan ORF beserta koordinat, panjang, dan frame. ORF terpanjang dipilih sebagai frame untuk klasifikasi dampak mutasi. Pendekatan ini menghilangkan kebutuhan anotasi eksternal untuk menentukan frame yang benar, meskipun untuk gen dengan alternative splicing masih memerlukan penanganan khusus. Modul mendukung tabel kodon standar (64 kodon, kode genetik universal) serta tabel kodon mitokondria vertebrata (kode genetik #2), di mana AGA/AGG menjadi stop codon, TGA mengkode Trp, dan ATA mengkode Met.

2.5 Klasifikasi Dampak Mutasi. Untuk tiap SNP pada posisi p , indeks kodon $k = \lfloor p/3 \rfloor$ dan posisi dalam kodon $p \bmod 3$. Dampak: SILENT (asam amino sama), MISSENSE (berubah), NONSENSE (stop prematur), START_LOST, STOP_LOST, atau FRAMESHIFT.

2.6 Conservation Scoring. *Conservation scoring* menilai seberapa penting posisi tertentu pada genom berdasarkan tiga komponen. Komponen pertama adalah posisi dalam kodon: posisi ke-1 dan ke-2 lebih

conserved (skor 1,0) dibanding posisi ke-3 (wobble, skor 0,3), karena redundansi kode genetik terutama terletak pada posisi ketiga. Komponen kedua adalah Grantham distance [7], yaitu jarak biokimia antara asam amino referensi dan alternatif yang mengukur perbedaan komposisi, polaritas, dan volume molekul (range 0–215). Matriks lengkap 190 pasangan asam amino diimplementasikan dalam pipeline. Komponen ketiga adalah impact severity: NONSENSE mendapat skor 1,0, MISSENSE 0,7, dan SILENT 0,1. Ketiga komponen digabung dengan bobot 0,30:0,40:0,30 menjadi skor conservation tunggal (0,0 = benign, 1,0 = highly damaging). Pada implementasi produksi, skor ini biasanya digantikan oleh PhyloCSF atau GERP yang menggunakan multi-species alignment dari puluhan spesies vertebrata [8].

2.7 Anotasi ClinVar. Modul anotasi ClinVar melakukan lookup terhadap database varian klinis yang diketahui. Setiap entry berisi variant_id, nama gen, notasi HGVS pada level coding DNA dan protein, clinical significance (Pathogenic, Likely pathogenic, VUS, Likely benign, Benign), kondisi penyakit terkait, review status, frekuensi alel populasi, dan jumlah bukti pendukung. Clinical significance dikonversi ke skor numerik (Pathogenic=1,0; VUS=0,5; Benign=0,0), dan review status ke confidence score (practice guideline=1,0; no assertion=0,3). Pada implementasi ini, digunakan simulated ClinVar database yang berisi varian-varian terkenal termasuk HBB sickle-cell (CV000015333), hemoglobin C (CV000015334), β -thalassemia, serta varian BRCA1 dan TP53 untuk demonstrasi.

2.8 Klasifikasi Region. Posisi SNP diklasifikasi: EXON_CODING (criticality 0,80), SPLICE_SITE (± 2 bp, criticality 0,95), INTRON (0,15), 5' _UTR (0,40), 3' _UTR (0,30), PROMOTER (0,35).

2.9 Penilaian Patogenisitas. Modul menggabungkan seluruh hasil analisis menjadi skor patogenisitas tunggal (0,0 = benign, 1,0 = highly pathogenic) menggunakan formula: PathScore = $w_1 \times \text{ConservationScore} + w_2 \times \text{ClinVarSeverity} + w_3 \times \text{RegionCriticality} + w_4 \times \text{RarityBonus}$, dengan bobot default $w_1 = 0,35$; $w_2 = 0,35$; $w_3 = 0,20$; $w_4 = 0,10$. Rarity bonus dihitung dari frekuensi alel populasi: varian yang sangat jarang (AF < 0,01%) mendapat skor mendekati 1,0 karena varian langka lebih mungkin patogenik. Jika ClinVar entry tidak ditemukan, bobot w_2 didistribusikan ulang secara proporsional ke komponen lain (60% ke conservation, 30% ke region, 10% ke rarity). Skor dikategorikan menjadi HIGH RISK ($\geq 0,8$), MODERATE RISK ($\geq 0,5$), LOW RISK ($\geq 0,3$), dan BENIGN (< 0,3). Confidence assessment ditentukan oleh review status ClinVar: HIGH jika practice guideline/expert panel, MEDIUM jika criteria provided, LOW jika tidak ada ClinVar data.

2.10 Dataset. Dua sumber: (1) sintetik 1.500 bp (GC=0,5, seed=42) dengan 150 SNP acak sebagai ground truth; (2) fragmen 60 bp ekson-1 gen HBB (wild-type vs sickle-cell).

2.11 Metrik Evaluasi. Precision = $\text{TP}/(\text{TP}+\text{FP})$, recall = $\text{TP}/(\text{TP}+\text{FN})$, F1 = $2 \cdot \text{P} \cdot \text{R}/(\text{P}+\text{R})$. SNP diidentifikasi oleh triple (posisi, REF, ALT).

2.12 Tautan Implementasi. Seluruh kode tersedia sebagai Jupyter Notebook di: [Tautan repositori]


3. Hasil dan Diskusi

3.1 Validasi pada Dataset Sintetik


Alignment Needleman–Wunsch pada sekuens sintetik (1.500 bp) menghasilkan alignment tanpa gap, konsisten karena sampel hanya berbeda berupa substitusi titik. Modul deteksi mengidentifikasi 150 SNP tanpa indel. ORF *auto-detection* berhasil menemukan reading frame konsisten. Evaluasi: Tabel 1.

Tabel 1. Evaluasi deteksi SNP pada dataset sintetik (1.500 bp, 150 SNP) vs. ground truth.


Metrik	Nilai
True Positive (TP)	150
False Positive (FP)	0
False Negative (FN)	0
Precision / Recall / F1	1,000 / 1,000 / 1,000



Gambar 1. Distribusi posisi 150 SNP pada sekuens sintetik 1.500 bp. Warna menunjukkan kategori dampak.




Gambar 2. Kiri: distribusi kategori dampak mutasi. Kanan: matriks substitusi REF → ALT.



Gambar 3. Kiri: conservation score per kategori dampak. Tengah: distribusi pathogenicity score. Kanan: Grantham distance vs pathogenicity score.

3.2 Validasi pada Kasus Biologis Nyata: HBB

Pada fragmen 60 bp gen HBB, pipeline mendeteksi tepat satu SNP: A→T pada posisi 19 (0-based), kodon ke-7. Translasi: GAG→GTG (Glu→Val), MISSENSE. Identik dengan mutasi sickle-cell Ingram [5]. Analisis klinis: conservation score 0,735 (posisi ke-2 kodon, Grantham distance 121); ClinVar match CV000015333 (Pathogenic, practice guideline, 42 submissions); region EXON_CODING; pathogenicity score 0,787 (MODERATE RISK, confidence HIGH).



Gambar 4. Hasil pipeline pada fragmen HBB. Kiri: posisi SNP. Kanan: kategori dampak (MISSENSE tunggal).


3.3 Eksperimen Sensitivitas terhadap Densitas Mutasi

Lima trial independen pada delapan tingkat densitas SNP (ref 1.500 bp). Hasil pada Tabel 2 dan Gambar 5.

Densitas (%)	Precision	Recall	F1
1,00	1,000 (,000)	1,000 (,000)	1,000 (,000)
2,00	1,000 (,000)	1,000 (,000)	1,000 (,000)

3,33	1,000 (,000)	1,000 (,000)	1,000 (,000)
6,67	1,000 (,000)	0,988 (,016)	0,994 (,008)
13,33	0,999 (,002)	0,993 (,010)	0,996 (,006)
20,00	0,997 (,005)	0,958 (,028)	0,977 (,016)
26,67	0,970 (,014)	0,840 (,020)	0,900 (,015)
33,33	0,953 (,034)	0,773 (,067)	0,853 (,054)

Tabel 2. Hasil eksperimen sensitivitas ($n=5$ trial; ref 1.500 bp). Format: mean (sd).



Gambar 5. Sensitivitas pipeline terhadap densitas SNP. $F1 \geq 0,97$ hingga 20%; recall turun di densitas tinggi karena aligner memilih gap.

Pipeline mempertahankan akurasi yang baik hingga 3,33%. Pada densitas $\geq 6,67\%$, recall mulai turun, sedangkan precision tetap tinggi. Pada 33,33%, F1 turun ke 0,853 - sekitar 23% SNP terlewat karena aligner memilih gap daripada mismatch berturut-turut.

3.4 Analisis Conservation dan Patogenesis

MISSENSE *mutations* memiliki *conservation score* lebih tinggi daripada SILENT karena perubahan pada posisi 1–2 kodon dengan Grantham distance signifikan. NONSENSE mendapat skor tertinggi. Korelasi positif antara Grantham distance dan *pathogenicity score* mengkonfirmasi *scoring function* menangkap *severity* biokimia.

Kasus HBB memberikan validasi biologis sangat kuat dimana *pipeline* mendeteksi tepat satu SNP dan mengklasifikasikannya sebagai *missense* Glu→Val, yang sama persis dengan mutasi penyebab hemoglobin S. Substitusi Val pada permukaan rantai β -globin menciptakan *hydrophobic patch* yang memicu polimerisasi dalam kondisi rendah oksigen, mengakibatkan eritrosit berbentuk sabit. *Pathogenicity score* 0,787 dengan *confidence high* mengkonfirmasi signifikansi klinis mutasi ini. Grantham distance Glu→Val = 121 menandakan perubahan dari asam amino bermuatan negatif (hidrofil) ke nonpolar (hidrofob), konsisten dengan mekanisme patologis yang diketahui.

Distribusi kategori dampak pada dataset sintetik bersifat *instructive* artinya mayoritas SNP menghasilkan MISSENSE, mencerminkan struktur kode genetik standar di mana hanya posisi ketiga kodon yang umumnya *degenerate*. Rata-rata *pathogenicity score* untuk MISSENSE (0,665) secara signifikan lebih tinggi daripada SILENT (0,379), sementara NONSENSE mencapai 0,872 atau mendekati skor maksimum, menunjukkan *scoring function* berhasil menangkap *hierarchy* dampak biologis.

Dari sisi sensitivitas, penurunan *recall* pada densitas tinggi ($\geq 20\%$) dinilai wajar menggunakan Needleman-Wunsch dengan skema *match*=+2, *mismatch*=−1, *gap_open*=−2 kadang memilih satu *match* + *gap* daripada dua *mismatch* berturut-turut, karena $(+2) + (-2) = 0 > (-1) + (-1) = -2$. Akibatnya, SNP yang berdekatan dapat tersembunyi sebagai pasangan INS+DEL. Skema skoring dengan penalti gap lebih ketat (*open_gap* = −5) atau penggunaan matriks substitusi transisi/transversi (Ti/Tv) yang membedakan jenis substitusi dapat memperbaiki recall pada densitas tinggi tanpa mengorbankan precision.

4. Kesimpulan dan Saran

Pipeline Python modular ini berhasil menyatukan konsep biologi dengan algoritma Needleman–Wunsch melalui fitur seperti *auto-detection* enam *reading frame* ORF serta sistem penilaian patogenisitas yang menggabungkan Grantham distance, anotasi ClinVar, dan klasifikasi region genomik. Validasi sistem menunjukkan presisi, recall, dan F1 score yang baik pada dataset sintetik 1.500 bp dengan 150 SNP, serta keberhasilan identifikasi mutasi *sickle-cell* Glu6Val pada gen HBB dengan skor patogenisitas 0,787 (MODERATE RISK, *confidence* HIGH). Pengukuran kuantitatif pada delapan tingkat densitas SNP (1,0–33,3%) mengonfirmasi reliabilitas yang baik dengan $F1 \geq 0,97$ hingga ambang densitas 20%, meskipun implementasi ini masih memiliki keterbatasan operasional seperti penggunaan *database* ClinVar simulasi, skor konservasi heuristik (belum menggunakan PhyloCSF/GERP), klasifikasi region manual (belum parsing GFF/GTF), serta kompleksitas algoritma $O(m.n)$ yang membatasi skalabilitas pada genom utuh dibandingkan alat industri seperti BWA atau minimap2.

Saran penelitian lanjutan (1) integrasi ClinVar API nyata untuk anotasi real-time; (2) integrasi PhyloCSF/GERP untuk conservation score berbasis multi-species alignment; (3) parsing GFF/GTF untuk anotasi gen otomatis dari Ensembl/RefSeq; (4) machine learning classifier untuk prediksi patogenisitas dari fitur yang sudah dibangun; (5) ekstensi ke deteksi varian struktural (inversi, duplikasi, CNV); (6) output VCF standar untuk interoperabilitas dengan tools bioinformatika lain; (7) optimisasi ke implementasi linear-space (Hirschberg) atau seed-and-extend untuk skalabilitas genom utuh.

5. Kontribusi Anggota

Lorem

6. Tautan Pengerjaan

Tabel X. Tautan Deliverable

Deliverable	Tautan
Repository	https://github.com/suryasuharna23/SNP-Detection-Komputasi-Domain-Spesifik
Notebook	
YouTube	

Daftar Pustaka

- [1] S. T. Sherry et al., “dbSNP: the NCBI database of genetic variation,” *Nucleic Acids Res.*, vol. 29, no. 1, hlm. 308–311, 2001.
- [2] D. W. Mount, *Bioinformatics: Sequence and Genome Analysis*, 2nd ed. CSHL Press, 2004.
- [3] S. B. Needleman dan C. D. Wunsch, “A general method applicable to the search for similarities in the amino acid sequence of two proteins,” *J. Mol. Biol.*, vol. 48, no. 3, hlm. 443–453, 1970.
- [4] P. J. A. Cock et al., “Biopython: freely available Python tools for computational molecular biology,” *Bioinformatics*, vol. 25, no. 11, hlm. 1422–1423, 2009.
- [5] V. M. Ingram, “Gene mutations in human haemoglobin,” *Nature*, vol. 180, hlm. 326–328, 1957.
- [6] M. J. Landrum et al., “ClinVar: improvements to accessing data,” *Nucleic Acids Res.*, vol. 48, no. D1, hlm. D835–D844, 2020.
- [7] R. Grantham, “Amino acid difference formula to help explain protein evolution,” *Science*, vol. 185, hlm. 862–864, 1974.
- [8] K. S. Pollard et al., “Detection of nonneutral substitution rates on mammalian phylogenies,” *Genome Res.*, vol. 20, no. 1, hlm. 110–121, 2010.
- [9] T. F. Smith dan M. S. Waterman, “Identification of common molecular subsequences,” *J. Mol. Biol.*, vol. 147, hlm. 195–197, 1981.
- [10] H. Li, “Minimap2: pairwise alignment for nucleotide sequences,” *Bioinformatics*, vol. 34, no. 18, hlm. 3094–3100, 2018.